Práctica 4: Neo4j

Martínez Ostoa Néstor Iván Bases de Datos No Estructuras - 0600 Ciencia de Datos, IIMAS, UNAM

Junio 2021



1. Introducción

Neo4j es una base de datos gráfica (graph database). En ella se pueden implementar algoritmos de gráficas complicados (como el encontrar la ruta mínima entre dos nodos) manteniendo una sencillez a la hora del modelado. Neo4j utiliza Cypher como su lenguaje de consultas y el medio principal de comunicación con la base de datos. La principal diferencia que existe con una base de datos relacional es que Neo4j almacena la información como un grafo.

1.1. Modelado en Neo4j

Para realizar el modelado de la base de datos, tenemos que tener en consideración los siguientes elementos:

- Nodos: son la entidad más elemental en Neo4j y son el serían el equivalente a una tabla en el modelado relacional. Estos nodos pueden tener propiedades que los diferencien de otros
- Relaciones: son el segundo elemento fundamental para el modelado en Neo4j. Las relaciones son un aspecto fundamental porque indican la manera de interconexión entre los nodos. Las relaciones, al igual que los nodos, pueden tener propiedades que ayuden a identificar patrones en los nodos

1.2. Cypher

Cypher es el lenguaje de programación con el que programadores interactúan con Neo4j para realizar todas las operaciones principales. Tiene una notación muy peculiar, a pesar de realizar actividades muy similares a SQL. Derivado de esto, a continuación se muestra un ejemplo de algunas operaciones básicas en Neo4j.

■ Creación de un nodo

```
1 CREATE (ee:Person { name: "Emil", from: "Sweden", klout: 99 })
```

• Creación de otros nodos junto con relaciones básicas

```
MATCH (ee:Person) WHERE ee.name = "Emil"

CREATE (js:Person { name: "Johan", from: "Sweden", learn: "surfing" }),

(ir:Person { name: "Ian", from: "England", title: "author" }),

(rvb:Person { name: "Rik", from: "Belgium", pet: "Orval" }),

(ally:Person { name: "Allison", from: "California", hobby: "surfing" }),

(ee) -[:KNOWS {since: 2001}] -> (js), (ee) -[:KNOWS {rating: 5}] -> (ir),

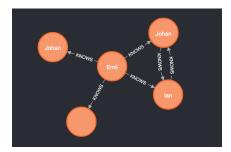
(js) -[:KNOWS] -> (ir), (js) -[:KNOWS] -> (rvb),

(ir) -[:KNOWS] -> (js), (ir) -[:KNOWS] -> (ally),

(rvb) -[:KNOWS] -> (ally)
```

Búsqueda en el grafo

```
MATCH (ee:Person)-[:KNOWS]-(friends)
WHERE ee.name = "Emil" RETURN ee, friends
```

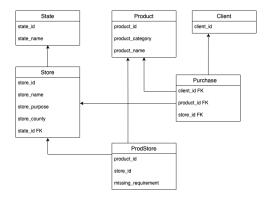


2. Desarrollo

Con base en los datos de Normatividad Mercantil de la PROFECO para el 2015, realicé una base de datos tipo grafo con los apartados descritos a continuación.

2.1. Modelo de grafo

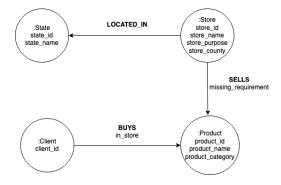
Para modelar el grafo solución a este problema, empecé un punto atrás. En un modelo relacional que me ayudara a estructurar las diversas entidades. El modelo se muestra a continuación:



El modelo consta de las siguientes entidades:

- State: representa una entidad federativa mexicana
- Store: representa cada una de las tiendas encontradas en los datos originales. Esta entidad contiene un atributo llamado store_county que representa el municipio en el que se encuentra la tienda. La razón de hacer esto se debe a que existían múltiples tiendas con el mismo nombre (tiendas OXXO por ejemplo) y en el preprocesamiento de los datos, ocupé el atributo del municipio para diferenciarlas
- Product: representa un producto. La product_category corresponde al campo tipo producto de la fuente de datos original y el campo product_name corresponde al campo descripcion producto
- Client: representa un cliente
- Purchase: representa una tabla encargada de almacenar el producto que compró un cliente junto con la tienda en donde lo compró
- ProdStore: representa una entidad encargada de almacenar los productos que ofrece cada tienda. El campo missing_requirement se encarga de almacenar si el producto, para esa tienda en específico, cuenta con algún incumplimiento reglamentario

Una vez diseñado el modelo anterior, podemos pasar a diseñar el modelo del grafo que cargaremos a Neo4j. De nuevo, el modelo de grafo se muestra primero y luego su explicación:



En este modelo podemos ver que tenemos solo cuatro nodos. A continuación se describen con mayor detalle:

- :State: representa una entidad federativa y se relaciona con el nodo :Store a través de la relación LOCATED_IN
- :Store: representa una tienda y se relaciona con el nodo :Product mediante la relación SELLS la cual tiene como atributo missing_requirement que es una cadena que indicará el resultado de la visita de la PROFECO. Es decir, en este campo se guardará si el producto tiene o no incumplimiento con alguna norma oficial
- :Client: representan a los consumidores de productos y se relaciona con el nodo :Product por medio de la relación BUYS la cual tiene como propiedad in_store el cual almacenará el id de la tienda en donde se realizó la compra de ese producto
- :Product: representan los productos ofrecidos por las tiendas

2.2. Preprocesamiento de datos

El preprocesamiento de los datos lo realicé en el archivo code.ipynb, en él, se encuentra con mayor detalle las etapas en Python para limpiar y preprocesar los datos. A grandes rasgos, lo que hice fue lo siguiente:

- 1. Generar un catálogo de estados con el campo ENTIDAD
- 2. Generar un catálogo de tiendas tomando los campos RAZON SOCIAL y MUNICIPIO como identificador único para cada una de las tiendas. Esto lo hice para evitar duplicados en las tiendas
- 3. Generar un catálogo de productos tomando los campos TIPO PRODUCTO y DESCRIPCION PRODUCTO como llave única para evitar duplicados
- 4. Crear una entidad que contuviera la relación descrita por la entidad **ProdStore** del modelo relacional en donde se almacenan todos los productos vendidos por cada tienda al igual que un posible incumplimiento de alguna norma
- 5. Generar un catálogo de 50,000 clientes
- 6. Simular compras para cada uno de los 50,000 clientes. Esto lo realicé con números aleatorios para establecer:
 - Cantidad de compras realizadas por cliente
 - Tiendas en las que el cliente realizó una compra
 - Productos aleatorios vendidos por las tiendas previamente seleccionadas como parte de su historia de compras

Todos estos pasos los almacené en archivos separados por coma (csv). A continuación se muestran los links para visualizar cada uno de estos:

- Datos originales
- Catálogos de estados

- Catálogos de tiendas
- Catálogos de productos
- Productos vendidos por tienda
- Catálogo de clientes
- Historial de compras por cliente

2.3. Inserción de datos

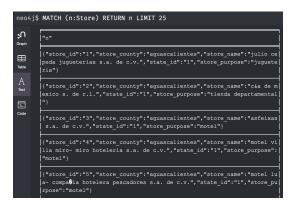
Para la inserción de datos en Neo4j ¹ seguí los siguientes pasos:

1. Carga de estados (entidades federativas)

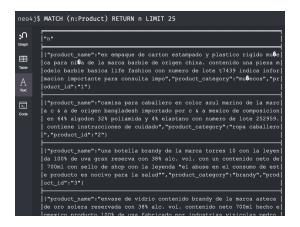


2. Carga de tiendas

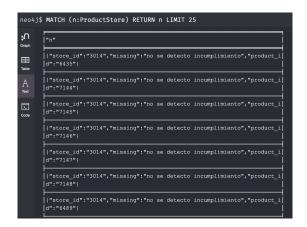
 $^{^{1}}$ s-01-load-data.cql



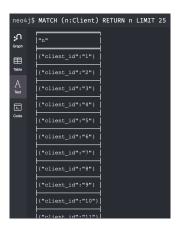
3. Carga de productos



4. Carga de productos vendidos por tienda



5. Carga de clientes



6. Carga de compras



2.4. Creación del grafo

Para la creación del grafo ² tuve que juntar los datos recién agregados con las relaciones previamente definidas en el modelo del grafo. A continuación muestro con mayor detalle este proceso:

1. State \leftarrow Store

```
1 MATCH (store:Store),(state:State)
2 WHERE store.state_id = state.state_id
3 CREATE (store)-[:LOCATED_IN]->(state)
```





2. Store \rightarrow Product

```
MATCH (s:Store),(p:Product),(ps:ProductStore)
WHERE ps.store_id = s.store_id AND ps.product_id = p.product_id
CREATE (s)-[:SELLS {missing: ps.missing}]->(p)
```

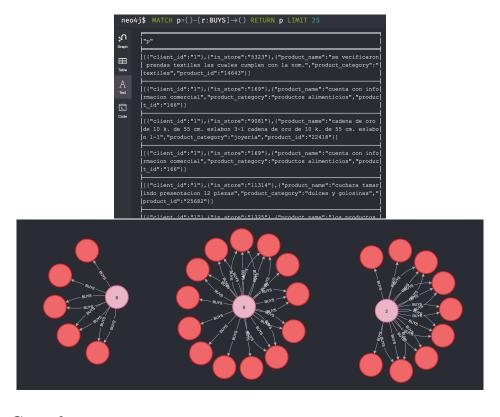
²s-02-relationships.cql





3. Client \rightarrow Product

```
MATCH (c:Client),(p:Product),(s:Store),(pu:Purchase)
WHERE pu.client_id = c.client_id AND
pu.product_id = p.product_id AND
pu.store_id = s.store_id
CREATE (c)-[:BUYS {in_store: s.store_id}]->(p)
```

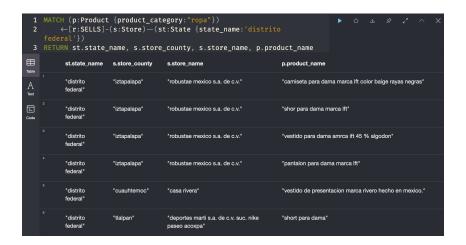


2.5. Consultas

El desarrollo de las consultas 3 se muestra a continuación:

 $^{^3}$ s-03-queries.cql

1. Búsqueda de productos



2. Verificación de incumplimiento en tiendas

```
// 2. Dado un estado y una tienda, verificar si tiene algun incumplimiento con
// un producto

MATCH (st:State {state_name:'distrito federal'})

-[r:LOCATED_IN]-(s:Store {store_name:'cadena comercial oxxo s.a. de c.v.'})

-[r2:SELLS]->(p:Product)

WHERE r2.missing <> "no se detecto incumplimiento"
RETURN st.state_name, s.store_name, r2.missing
```

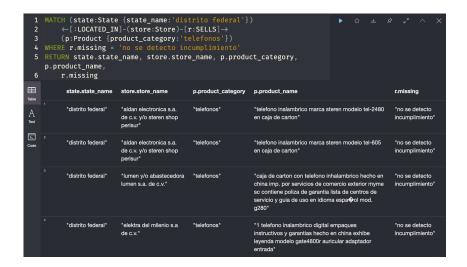


3. Buscador de productos o categorías alternativas que no tengan incumplimiento

```
// 3. Dado un estado y un producto, buscar alternativas sin incumplimiento de
    ese
// producto o categoria.

// Primero busco productos sin cumplimiento
MATCH (state:State {state_name:'distrito federal'})
    <-[:LOCATED_IN]-(store:Store)-[r:SELLS]->(p:Product)
WHERE r.missing <> 'no se detecto incumplimiento'
RETURN state.state_name, store.store_name, p.product_category, p.product_name,
    r.missing
```

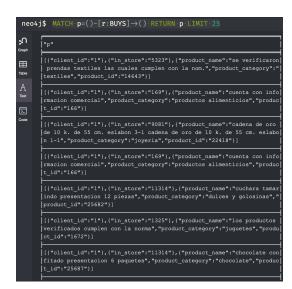


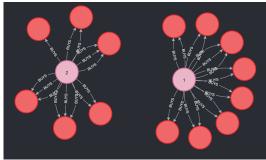


4. Registro de compras y lugares visitados por usuario

```
// Registro de compras y lugares visitados por usuario

MATCH p=()-[r:BUYS]->() RETURN p LIMIT 25
```

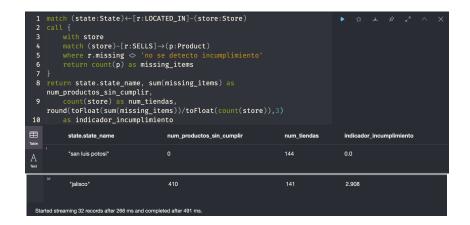




5. Búsqueda de estados con mayor y menor incumplimiento relativo al número de tiendas en ese estado

```
1 // 5. Encontrar los estados con mayor y menor incumplimiento relativo al numero
2 // de tiendas que tiene.
3
4 match (state:State) <-[r:LOCATED_IN]-(store:Store)
5 call {</pre>
```

```
with store
match (store)-[r:SELLS]->(p:Product)
where r.missing <> 'no se detecto incumplimiento'
return count(p) as missing_items
}
return state.state_name, sum(missing_items) as num_productos_sin_cumplir,
count(store) as num_tiendas, round(toFloat(sum(missing_items))/toFloat(count(store)),3)
as indicador_incumplimiento
order by indicador_incumplimiento
```



3. Conclusiones

Sin lugar a dudas que Neo4j es una base de datos muy versátil. A lo largo de esta práctica pude implementar preguntas que son difíciles de responder desde el punto de vista computacional de manera muy sencilla mediante un comando en Cypher. Sin embargo, algo a notar es que cree aproximadamente 1.2 millones de registros de compras y la herramienta Neo4j Desktop decrementó su rendimiento sustancialmente. Las consultas tardaban más tiempo en ejecutar de lo normal.

Aunado a esto, algo que me encantó de Neo4j es la facilidad con la que se pueden resolver problemas de gráficos muy complejos manteniendo un modelado extremadamente sencillo si vienes de un panorama relacional. La transición entre el modelado relacional al modelado en grafo es sumamenente sencillo y me atrevería a decir que incluso más sencillo que el relacional.

Referencias

- [1] Pimentel. Apuntes de Bases de Datos No Estructuradas: Neo4j. Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas. UNAM. México. 2021. Revisadas el 18 de junio del 2021
- [2] Vukotic A., Watt N., et. al. Neo4j in Action. Manning. 2015
- [3] Neo4j Docs. *The Neo4j Cypher Manual v4.3*. Revisado el 18 de junio del 2021 en: https://neo4j.com/docs/cypher-manual/current/

[4] Neo4j Docs. *Graph database concepts*. Revisado el 18 de junio del 2021 en: https://neo4j.com/docs/getting-started/current/graphdb-concepts/